# Statistica

Marta Barbero

# Statistica



# Terminologia

La statistica descrittiva ha lo scopo di descrivere e interpretare i cosiddetti **fenomeni collettivi** ovvero quei fenomeni che riguardano delle **popolazioni**.

Con il termine **popolazione** ci si riferisce ad un insieme di elementi che presentano tutti delle caratteristiche comuni, gli elementi di questo insieme li chiameremo **individui** o **unità statistiche**.

Esempi di popolazioni:

- *Insieme delle persone che vivono in Svizzera*
- *Cittadini che hanno diritto al voto*
- *Le aziende agrarie del Ticino*
- *Gli studenti universitari che frequentano un'università in Ticino*

# Terminologia

Una popolazione statistica si può classificare in vari modi in relazione alle **variabili statistiche**, ovvero alle qualità, o **caratteri**, dei singoli elementi.

Uno degli scopi della statistica è lo studio di **come si distribuisce una data popolazione in relazione a uno o più variabili**.

Le variabili possono essere:

- **Qualitative**: espresse in forma verbale, possono avere diverse manifestazioni dette **modalità**.

  *Es: la variabile «colore degli occhi» ha le modalità: celesti, grigi, neri, ...*

- **Quantitative**: espresse in forma numerica, i numeri con cui vengono espressi sono chiamati **valori**.

  *Es: la variabile «statura» ha diversi valori: 1.75 cm, 1.56 cm, 1.67 cm, ...*

# Terminologia

Si chiama **frequenza assoluta** ($f$) il numero che esprime quante volte si è manifestata una data modalità o un dato valore.

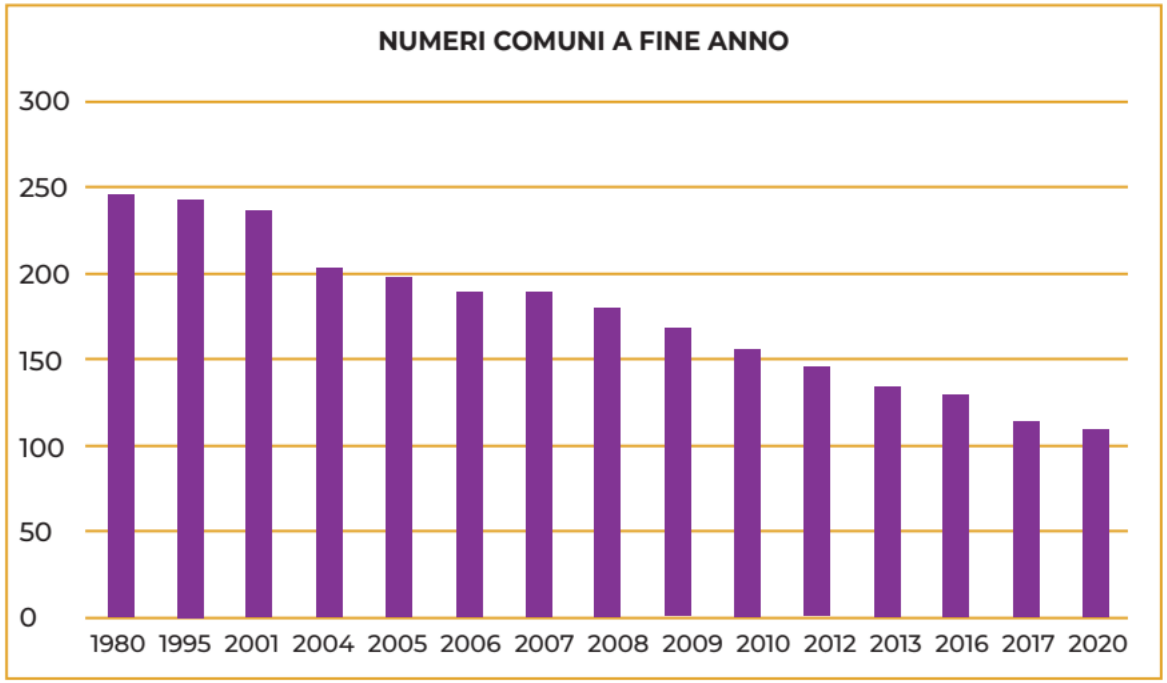
*Es: in un gruppo di persone si contano 10 svizzeri, 5 italiani, 7 inglesi.*

$$f_{sv} = 10 \quad f_{it} = 5 \quad f_{in} = 7$$

Le frequenze assolute possono essere sistemate in tabelle o grafici. Questi rappresentano le **distribuzioni di frequenza** e indicano come il totale degli individui della popolazione si suddivida tra le diverse voci.

ATTENZIONE: Le frequenze assolute di due distribuzioni non sono confrontabili.

**Comuni del Canton Ticino**



# Terminologia

Si chiama **frequenza relativa** ($f_r$) di una modalità (o di un valore) il rapporto tra la frequenza assoluta di tale modalità (o valore) e il numero di casi totali.

*Es: in un gruppo di persone si contano 10 svizzeri, 5 italiani, 7 inglesi.*

$$f(svizzeri) = 10 \quad f(italiani) = 5 \quad f(inglesi) = 7$$

$$f_r(svizzeri) = \frac{10}{22} \quad f_r(italiani) = \frac{5}{22} \quad f_r(inglesi) = \frac{7}{22}$$

Le frequenze relative di due distribuzioni possono essere confrontate. Può tornare utile in questo senso esprimere le **frequenze percentuali** identificando con quale proporzione si distribuiscono le modalità (o i valori).

$$f_r(svizzeri) = \frac{10}{22} \times 100 \quad f_r(italiani) = \frac{5}{22} \times 100 \quad f_r(inglesi) = \frac{7}{22} \times 100$$

*Circa il 45% delle persone sono svizzere, circa il 23% sono italiane e circa il 32% sono inglesi*

# Grafici e tabelle

I grafici e le tabelle sono delle **rappresentazioni di dati**, espressi in varie forme (numerica, a parole ecc.), che hanno lo scopo di renderli **facilmente consultabili e interpretabili**. Le tipologie di grafici e tabelle sono varie e si differenziano in base al metodo di rappresentazione e allo scopo specifico per cui vengono usate. Una rappresentazione può essere quindi più o meno funzionale a seconda dello scopo.

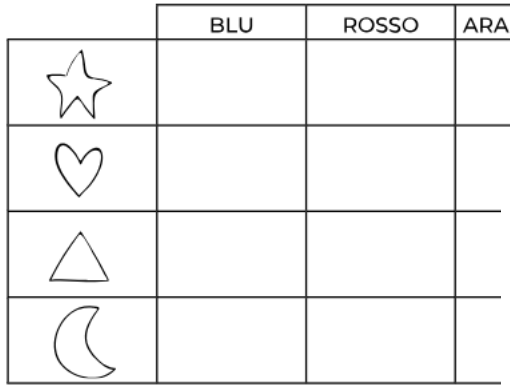
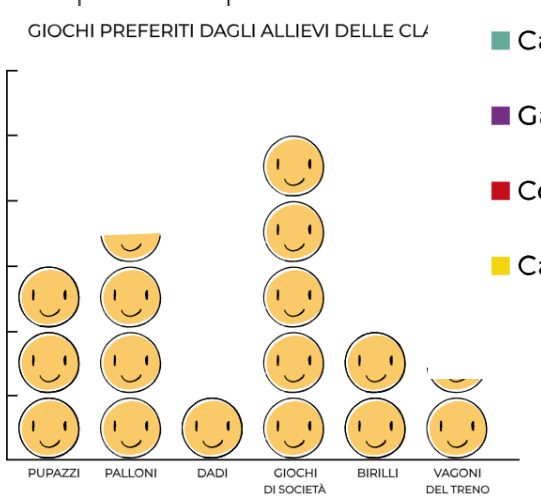


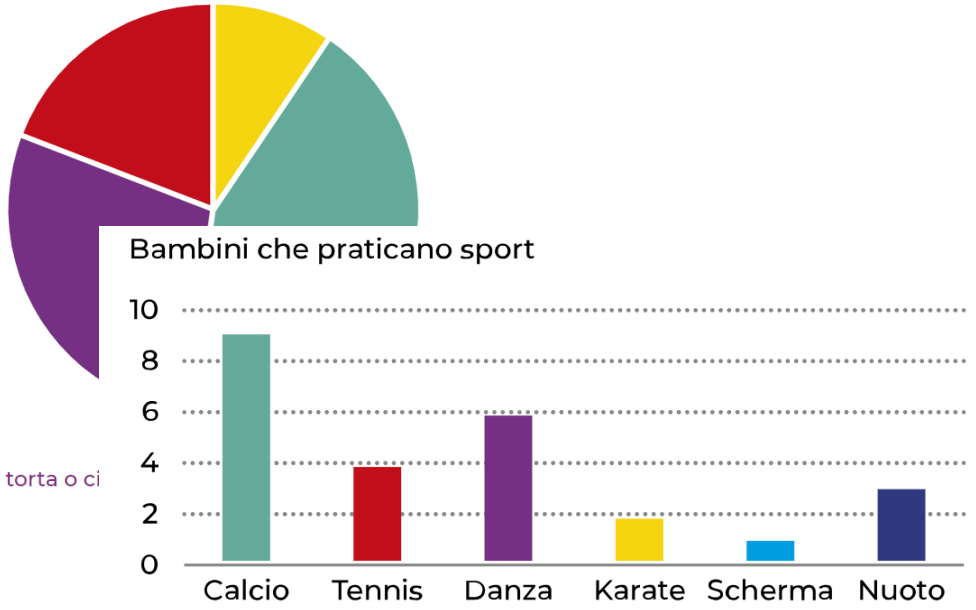

Tabella a doppia ent




Ideogramma.




Diagramma a torta o ci




Istogramma.

# Grafici e tabelle

| | BLU | ROSSO | ARANCIONE | VERDE |
|---|---|---|---|---|
|  | | | | |
|  | | | | |
|  | | | | |
|  | | | | |

Tabella a doppia entrata.

Una **tabella a doppia entrata** fornisce un'efficace visualizzazione degli insiemi su cui si considera la relazione, e delle caratteristiche delle coppie di elementi in relazione (gli incroci); questa rappresentazione può risultare efficace quando non è importante l'ordine tra gli insiemi.

# Grafici e tabelle

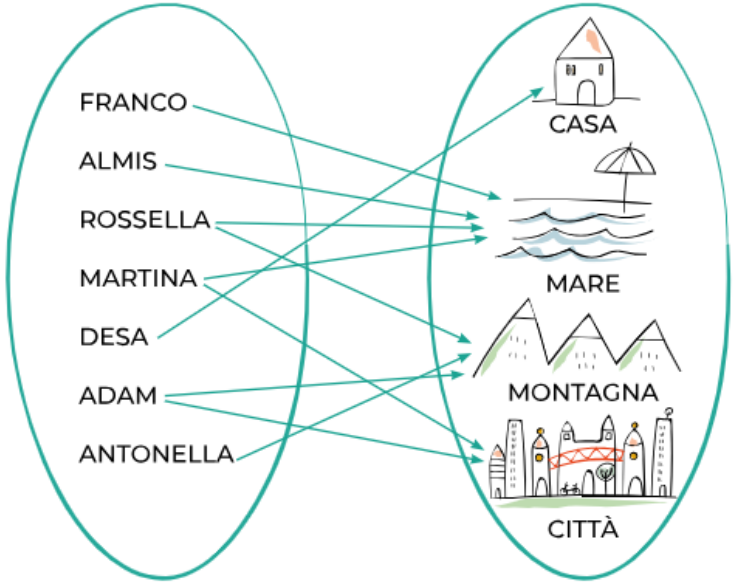
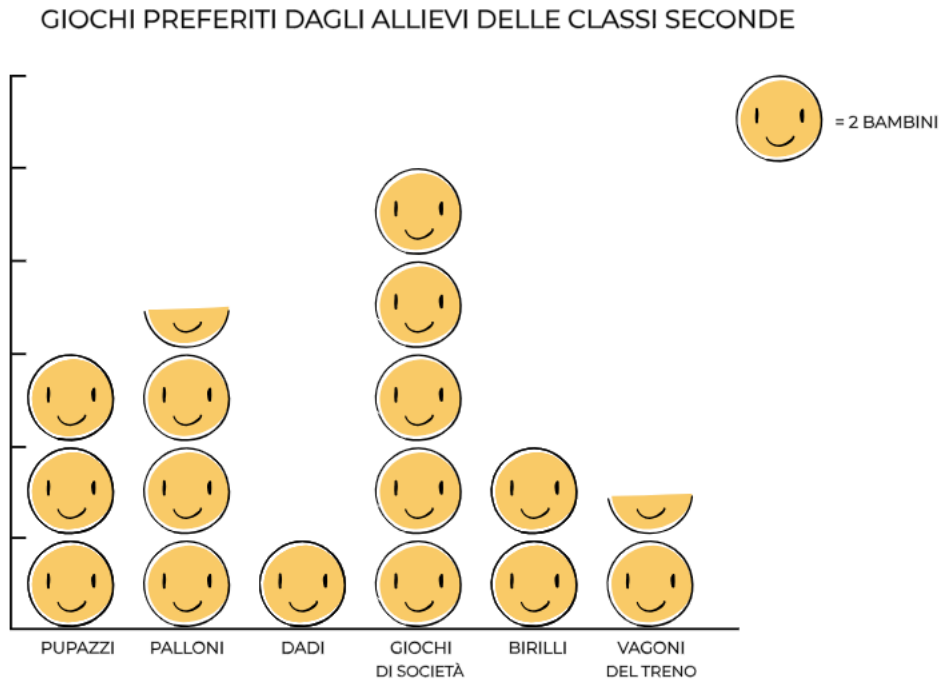



Diagramma sagittale o a frecce.

Il **diagramma sagittale o a frecce**, invece, è una rappresentazione che permette di visualizzare tramite collegamenti grafici, come le frecce, le relazioni che sussistono tra elementi di due insiemi.

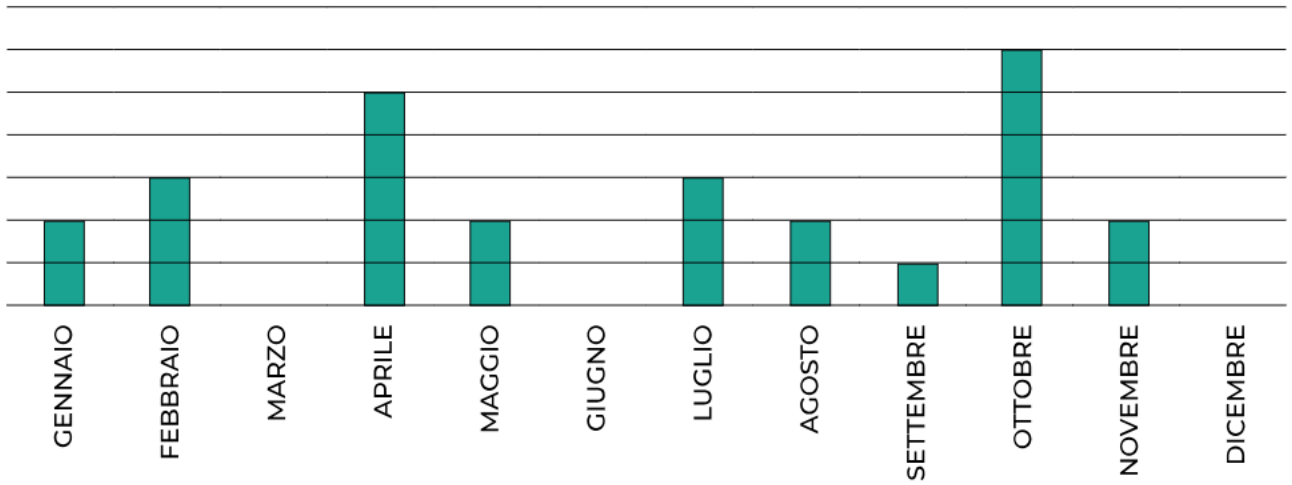
# Grafici e tabelle




Ideogramma.

L'**ideogramma** è una modalità di rappresentazione che usa immagini che evocano il fenomeno o la variabile considerata. È costituito da più simboli uguali ognuno dei quali indica un certo numero di elementi. Tale rappresentazione è molto usata nei quotidiani, in quanto fornisce informazioni di immediata lettura dei dati, soprattutto in termini di confronto, anche se potrebbero risultare piuttosto approssimative.

# Grafici e tabelle




Grafici a barre.

I **grafici a barre**, come ad esempio i **grafici a colonne e a nastri** (quando i rettangoli sono disposti in orizzontale), sono costituiti da tanti rettangoli quante sono le modalità da rappresentare, che vengono posizionati su un'asse di riferimento orizzontale (o rispettivamente verticale) e sono separati tra loro. La lunghezza dei lati dei rettangoli che si trovano sull'asse è fissa per ciascun rettangolo e scelta liberamente, mentre l'altezza è proporzionale alla frequenza o all'intensità che rappresentano.

# Grafici e tabelle

I grafici a barre sono assai diversi dagli **areogrammi** e dagli **istogrammi**, in quanto in questi ultimi casi la frequenza corrisponde all'area delle figure rappresentate di solito rispettivamente con settori circolari o con rettangoli.

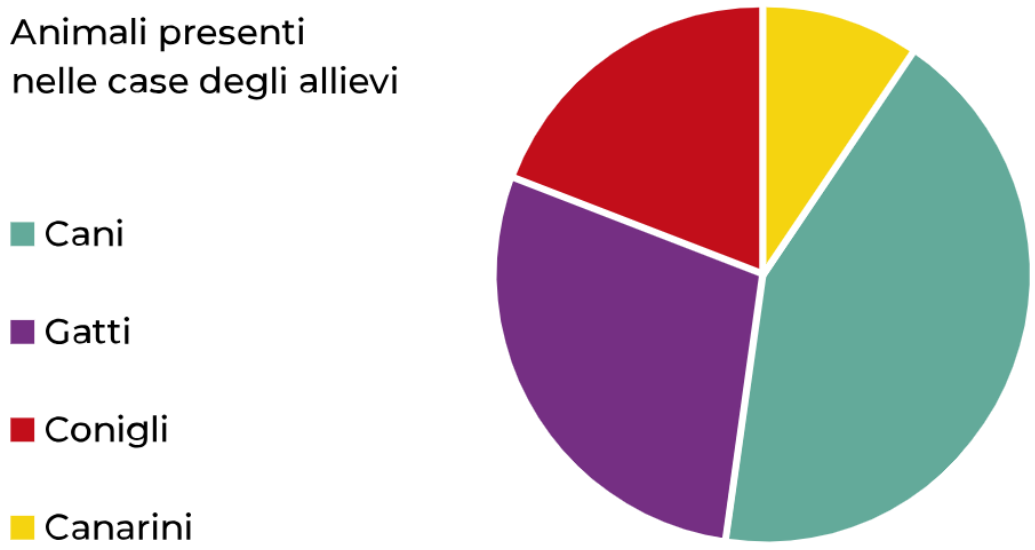
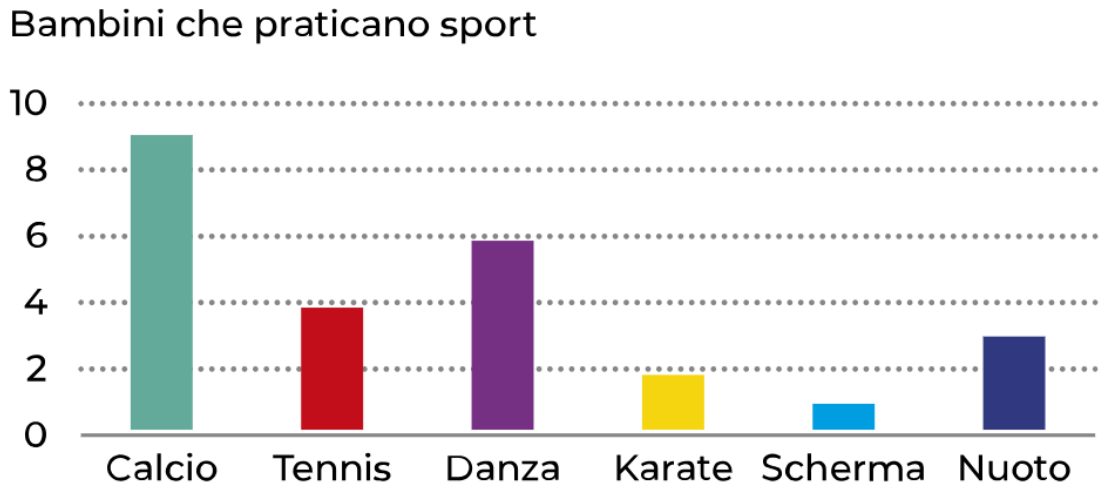



Diagramma a torta o circolare.




Istogramma.

# Grafici e tabelle

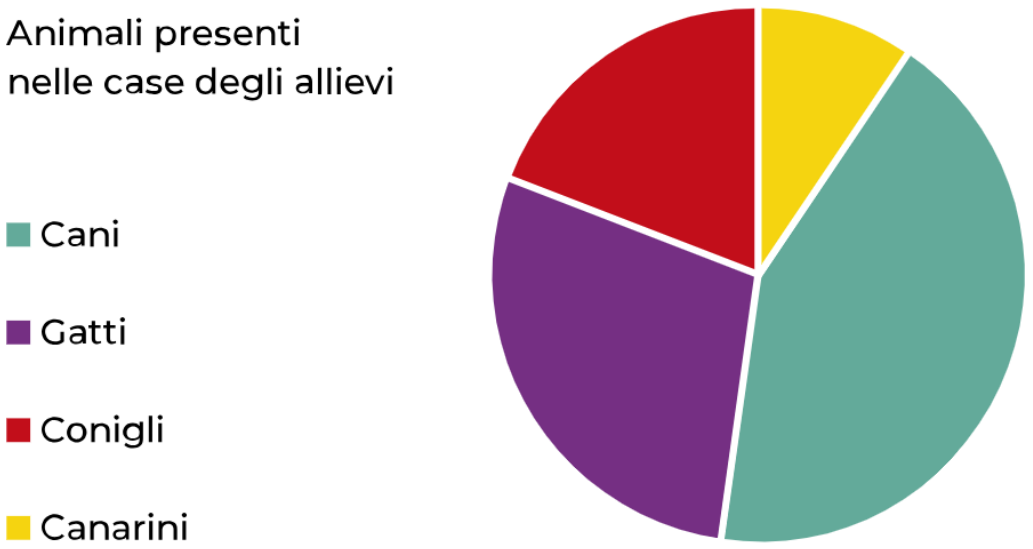
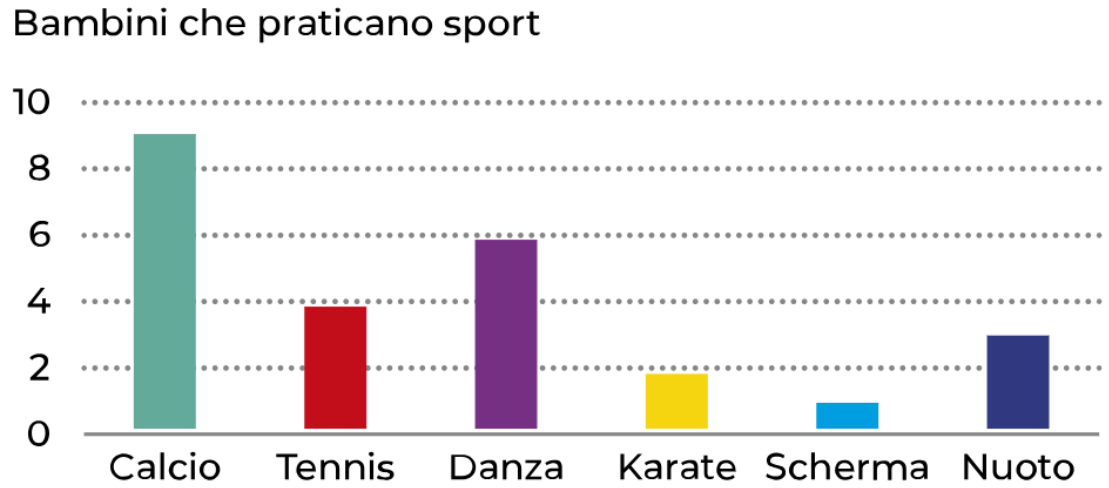



Diagramma a torta o circolare.

Quando è importante evidenziare il riferimento a un totale si usa un particolare tipo di areogramma detto **diagramma a torta** o **circolare**, nel quale le varie frequenze percentuali o relative sono raffigurate da ampiezze di angoli di settori circolari che dividono un cerchio. In questo modo l'area di ogni settore circolare risulta proporzionale alla percentuale rappresentata.

# Grafici e tabelle




Istogramma.

Si parla invece di **istogramma** se i dati numerici vengono rappresentati tramite aree di rettangoli, adiacenti tra loro e allineati su un asse orientato, dotato di unità di misura. Ogni rettangolo ha il lato sull'asse orientato di lunghezza pari all'ampiezza della corrispondente classe e l'altezza che rappresenta la densità di frequenza, ossia il rapporto fra la frequenza (assoluta) associata alla classe e l'ampiezza della classe. L'area della superficie di ogni rettangolo coincide con la frequenza associata alla classe cui il rettangolo si riferisce; per tale caratteristica gli istogrammi rappresentano un tipo di areogramma.

# Grafici e tabelle

I **diagrammi a due variabili** (*x, y*) (più raramente a tre) vengono utilizzati per rappresentare relazioni tra insiemi numerici, che si basano prevalentemente sul concetto di **piano cartesiano**.

Tale piano è costituito dall'asse delle ascisse che rappresenta una retta di riferimento (solitamente caratterizzata dalla lettera *x*), dall'asse delle ordinate, che costituisce una retta ortogonale alla precedente (solitamente caratterizzata dalla lettera *y*) e dall'origine, il punto nel quale si incontrano le due rette. Tramite questi elementi è possibile individuare ogni punto del piano con una coppia di numeri reali chiamati rispettivamente **ascissa** e **ordinata del punto**, i cui valori assoluti rappresentano le distanze del punto rispettivamente dall'asse *x* (ascissa) e dall'asse *y* (ordinata).
Determinati i punti sul grafico grazie alle due variabili, è possibile unirli se si vuole rappresentare un andamento. Se l'andamento è temporale, per convenzione, si rappresenta lo scorrere del tempo sull'asse orizzontale (*x*).

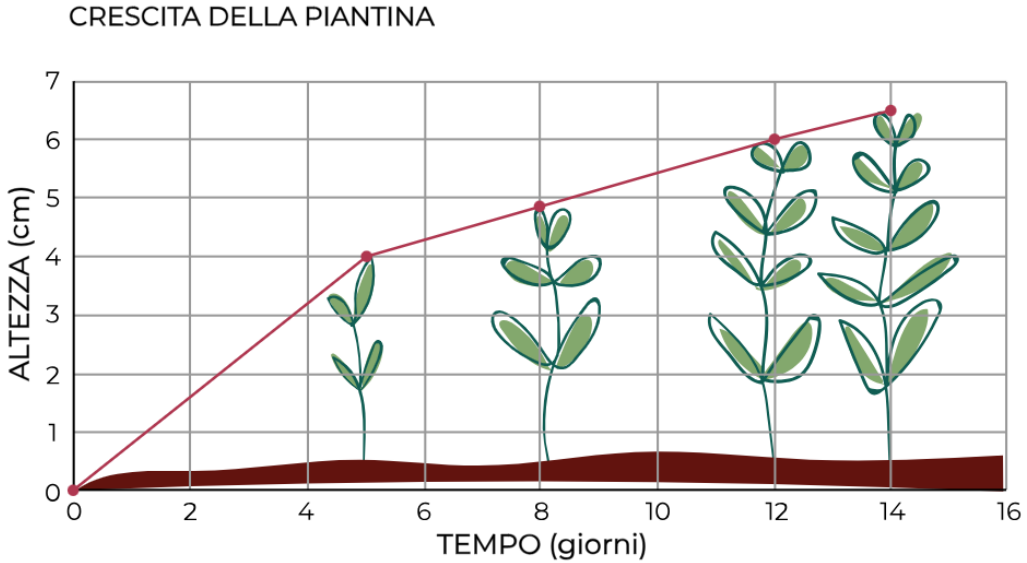



Diagramma a due variabili.

# Analisi delle distribuzioni statistiche

L'elaborazione matematica dei dati ci permette di ricavare delle informazioni riguardanti la popolazione che si sta studiando.

**Moda:** la modalità (o il valore) più frequente in una popolazione. Può non esistere e, se esiste, può non essere unica.

*Es: l'insieme {2, 3, 4, 4, 4, 5, 5, 7, 7, 7, 9} ha due mode 4 e 7.*

**Mediana:** data una distribuzione di valori posti in ordine non decrescente (o non crescente), è il valore che occupa il posto centrale nella distribuzione (se i valori sono in numero dispari) o la semisomma dei due valori centrali (se i valori sono in numero pari).

Es: l'insieme *{3, 4, 4, 5, 6, 8, 8, 8, 10} ha mediana 6.*

*Es: l'insieme {5, 5, 7, 9, 11, 12, 15, 15} ha mediana* $\frac{9+11}{2} = 10$

# Analisi delle distribuzioni statistiche

**Media aritmetica:** il numero che si ottiene sommando tutti i valori della distribuzione e dividendo per il numero totale dei valori.

*Es: la media dell'insieme {2, 3, 4, 4, 4, 5, 5, 7, 7, 7, 9} equivale a*

$$M = \frac{2+3+4+4+4+5+5+7+7+7+9}{11} = \frac{57}{11} = 5,\overline{18}$$

In una distribuzione di frequenze posso calcolare la **media aritmetica ponderata** sfruttando la frequenza dei diversi valori.

*Es: {1.75 cm, 1.75 cm, 1.75 cm, 1.75 cm, 1.75 cm, 1.75 cm, 1.56 cm, 1.56 cm, 1.56 cm, 1.86 cm, 1.68 cm, 1.68 cm, 1.68 cm, 1.68 cm}*

$$M = \frac{(1.75 \times 6 + 1.56 \times 3 + 1.86 + 1.68 \times 4)\ cm}{14} = 1{,}697..\ cm$$

# Analisi delle distribuzioni statistiche

Quantità come la media, la mediana o la moda vengono chiamate *statistiche* della popolazione che studiamo. Da qui il nome della disciplina.

Media e mediana sono statistiche che ci parlano di caratteristiche globalmente prevalenti ma non ci parlano di **quanto dominanti siano queste caratteristiche**.

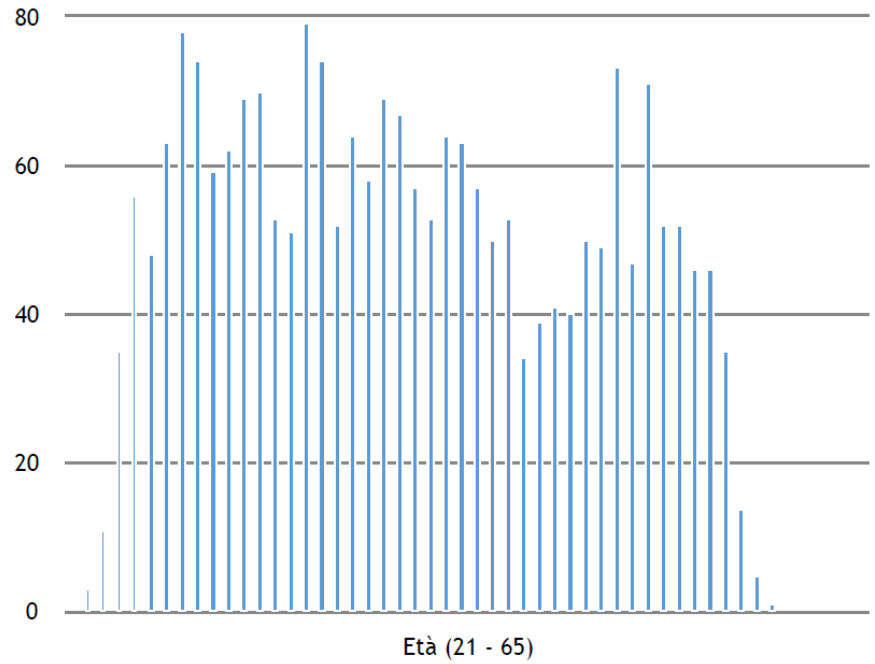
Osserviamo la rappresentazione della distribuzione di frequenza della variabile età di una popolazione di 2289 individui.

La moda è a 35 anni.

L'età media è 41,60 anni.

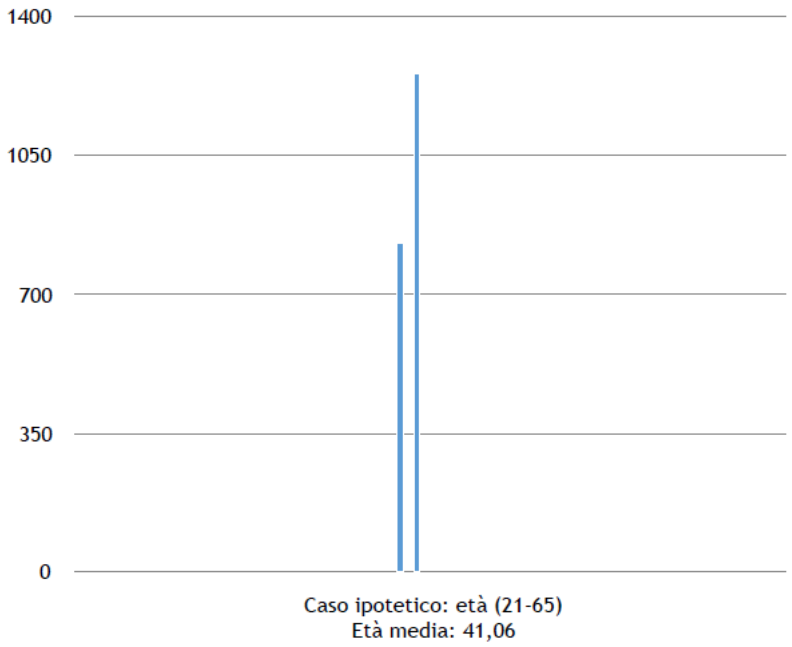
La mediana è a 45.5.

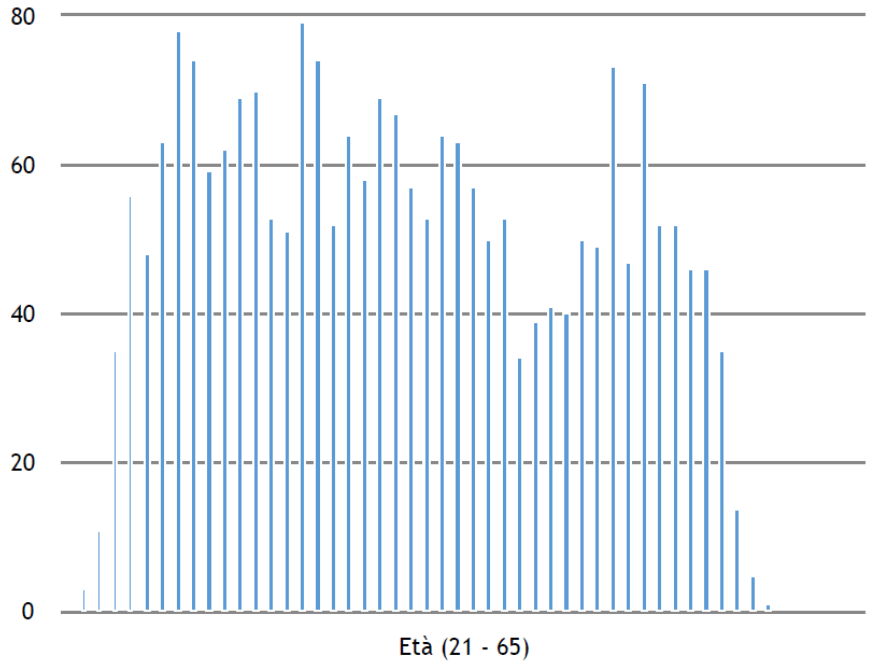
Questi valori ci dicono che la distribuzione delle età è più o meno "bilanciata" tra chi ha più o meno anni della media.



# Analisi delle distribuzioni statistiche

Dal grafico vediamo che ci sono molti individui che *non* hanno l'età media.




Otterremmo **lo stesso valore medio** se avessimo 830 individui di 41 anni e 1259 individui di 42 anni, e nessuno di un'altra età. In questo caso ipotetico diremmo che il valore dell'età è "concentrato" attorno al valore medio. Mentre nel caso reale diciamo che il valore dell'età è piuttosto "disperso" tra i vari valori possibili.

# Analisi delle distribuzioni statistiche

Una rappresentazione grafica ben scelta può comunicare in modo "visuale" immediato, pur se qualitativo, la **variabilità** dei valori di una variabile statistica e la loro eterogeneità.

